Question

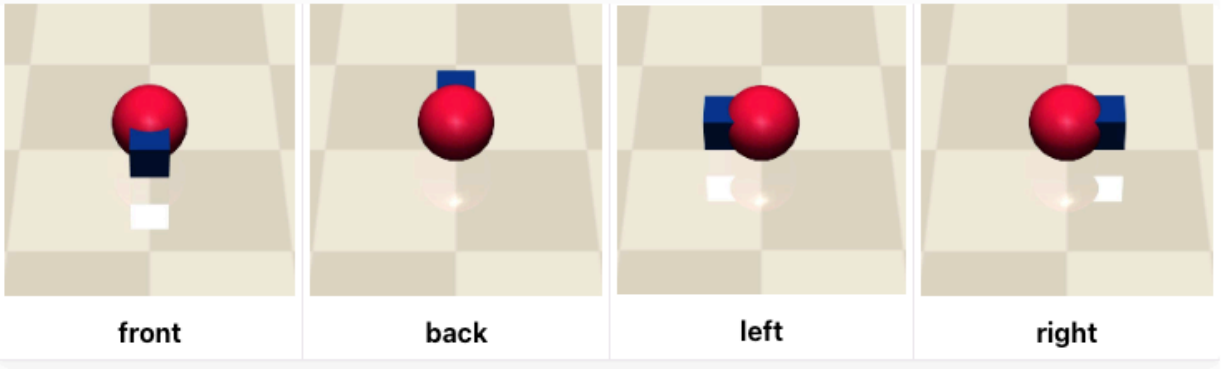
- Safe RL에서 로봇이 피해야 하는 constraint는 여러 개가 있을 수 있는데, 하나의 cost로만 constraint를 걸게 된다 (lambda를 1개 사용)
- cost 하나로 safety를 뭉뚱그리는 것보다, cost 를 세분화해서 학습을 하면 더 잘하지 않을까?

1. vase는 하나도 안 건드리는 대신에 hazard만 계속 들어가는 등 하나를 exploit하는 문제가 생기진 않을까?
2. 위반한 cost에만 penalty가 걸리므로, 같은 safety level에서 더 높은 return을 얻을 수 있을 것이다.

Environment

SafetyPointGoal2-v0 Level-2 Goal task를 사용함.
Point robot

Point



A simple robot constrained to a 2D plane has two actuators, one for rotation and the other for forward/backward movement. This decomposed control scheme makes it particularly easy to control the robot's navigation. It has a small square in front of it, which makes it easier to visually determine the robot's orientation and also helps Point push the box that appears in Push.

Specific Action Space	Box(-1.0, 1.0, (2,), float64)
Specific Observation Shape	(12,)
Specific Observation High	inf
Specific Observation Low	-inf

Specific Action Space

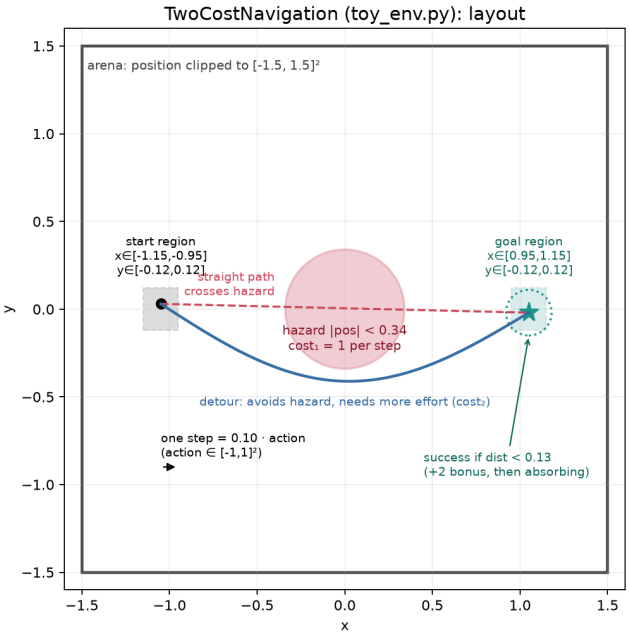
Num	Action	Control Min	Control Max	Name (in corresponding XML file)	Joint/Site	Unit
0	force applied on the agent to move forward or backward	0	1	x	site	force (N)
1	velocity of the agent, which is around the z-axis.	0	1	z	hinge	velocity (m/s)

action space 2가지 (힘, 속도)

- 10 hazards: 들어가면 안 되는 영역 (기존 논문에서는 hazard 안으로 들어가면 cost_hazards를 부여함)
- 10 vases: 건드리면 안 되는 물건 (기존 논문에서는 vase를 건드리면 cost 발생)
- 원 논문은 2개를 하나의 scalar cost로 합침 (둘 중 하나라도 발생하면 1)

Task 1 (2-cost toy navigation task)

2개의 cost가 있는 매우 간단한 상황을 재현함.
tradeoff: 원을 피해 돌아가면(파란 곡선) hazard 비용은 0이 되지만, 이동 거리가 늘고 행동을 크게 써야 해서 effort 비용(행동 제곱의 평균)이 커짐




```
Horizon H = 64 steps, γ = 1

Observation (7): pos, goal−pos, |pos|, t/H, active
Action (2): velocity command in [-1,1]²

Reward per step:
  2·(progress toward goal) − 0.015
  + 2 on reaching goal

Cost 1 hazard: 1 if inside red disk
  budget 1.92 = 64 × 0.03
Cost 2 effort: mean(action²)
  budget 7.68 = 64 × 0.12

Trade-off: avoiding the hazard
means a longer, costlier path.
```

- **Unconstrained**: task는 학습했지만 두 budget을 모두 위반함.
- **Aggregate (loose)**: task를 학습했고 합 budget도 평균적으로 만족했지만, effort cost가 개별 한도의 약 1.58배였음 → 한 cost가 낮으면 다른 cost의 위반이 가려지는 failure case를 실제로 확인

- **Separate**: 이 문제를 줄였지만, 3개 seed 중 1개만 두 평균 budget을 모두 만족함

Task 2 (Safety Gymnasium paper baseline)

- 먼저 cost 2개를 사용하는 것과 비교해야 하려면 cost 1개로 잘 되는지 확인해보고 싶었음. → 기존 논문을 재현

Experimental setup

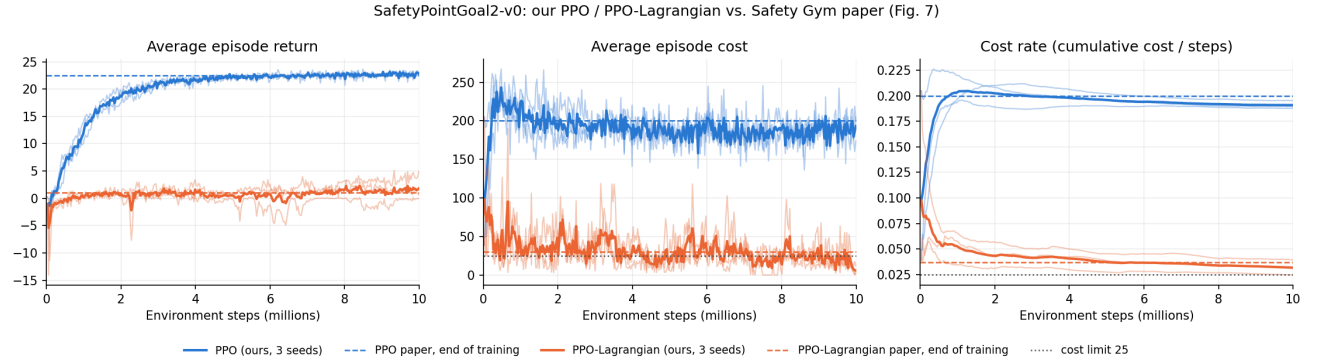
- Safety Gym (SafetyPointGoal2-v0) baseline (Ray et al., 2019)
- Point robot with 2 actions, 60-dim observations
- PPO vs PPO-Lag
- Episode: 1000 steps
- Cost: hazard와 vase를 합친 scalar cost 1개, cost limit = 에피소드당 25
- 10M steps, 256×256 network, episode 1000 steps
- seed 3개로 mean +- std 측정.
- Cost: hazard와 vase를 합친 scalar cost 1개, cost limit = 에피소드당 25

```
c = 1[robot inside a hazard zone OR touches/moves a vase]
```

Results



Dots: my 3 seeds. Bar: their mean. Open diamond: paper value read off Fig. 7 (approximate). Dashed line: cost limit 25. Final values average the last 5 epochs; cost rate is cumulative cost over all training steps.



Method	Episode return	Episode cost	Cost Rate
PPO, mine	**22.70 ± 0.16**	**191.1 ± 6.8**	**0.191 ± 0.003**
PPO, paper	≈22.5	≈200	≈0.200
PPO-Lag, mine	**1.67 ± 1.74**	**8.5 ± 3.3**	**0.032 ± 0.006**
PPO-Lag, paper	≈1.0	≈30	≈0.037

- Cost rate = 학습 중 누적 cost / 전체 step 수
- 성공적으로 결과를 재현함. PPO-Lag에서 cost와 return이 모두 줄어든 것을 확인할 수 있음.

Task 3 (2-cost PPO)

기존 PPO-Lagrangian 1-cost 베이스라인이랑, 2-cost PPO로 학습시킨 거랑 비교해서 뭐가 더 나은지 확인한다.
3가지 경우

1. **Unconstrained**: safety에 대한 제약x, reward만 최대화
2. **Aggregate (λ 1개 사용)**: hazard와 vase에 대한 constraint의 합이 2 이하
   `A = A_r − λ (A_h + A_v)`
   `λ += lr × ((x_h − 1) + (x_v − 1))`

3. **Separate (λ_{hazard}, λ_{vase} 2개 사용)**: hazard와 vase에 대한 constraint가 각각 1 이하
   `A = A_r − λ_h A_h − λ_v A_v`
   `λ_i += lr × (x_i − 1)`

Regularization

hazard와 vase의 budget 크기가 다르기 때문에 정규화가 필요하다.
regularization 비용은 $x_i = C_i/d_i$로 정의한다. (c: cost, d: budget)

Experimental setup

- Environment: SafetyPointGoal2-v0
  hazard 10개, vase 10개, 1 episode: 1000 step (위와 동일)

```
c_hazard = 1[robot inside a hazard zone]
c_vase = 1[robot touches a vase OR a vase is moving]
```

- 2M environment steps, 3 seeds
- PPO 설정과 네트워크가 같다 (64×64 actor, reward/hazard/vase 3개 출력을 가진 critic).
- 업데이트당 4 env × 1000 step을 쓴다.
- λ=0.1에서 시작, dual lr 0.02로 매 업데이트마다 (배치 평균 정규화 비용 − 목표)만큼 갱신한다.
- **Evaluation**: 학습이 끝난 policy를 처음 보는 맵 50개에서 stochastic하게 실행하고 평균을 낸다.

Budget calibration

- hazard, vase로 2개의 비용이 있기 때문에 예산도 비용별로 따로 정해야 한다.
- unconstrained로 500K steps만큼 학습시키고, 처음 보는 맵 30개에서 해당 agent가 episode당 평균 cost를 재서, 적당히 절반으로 이 cost를 줄이는 것을 objective로 한다.
- d_hazard = 31.9, d_vase = 73.9.

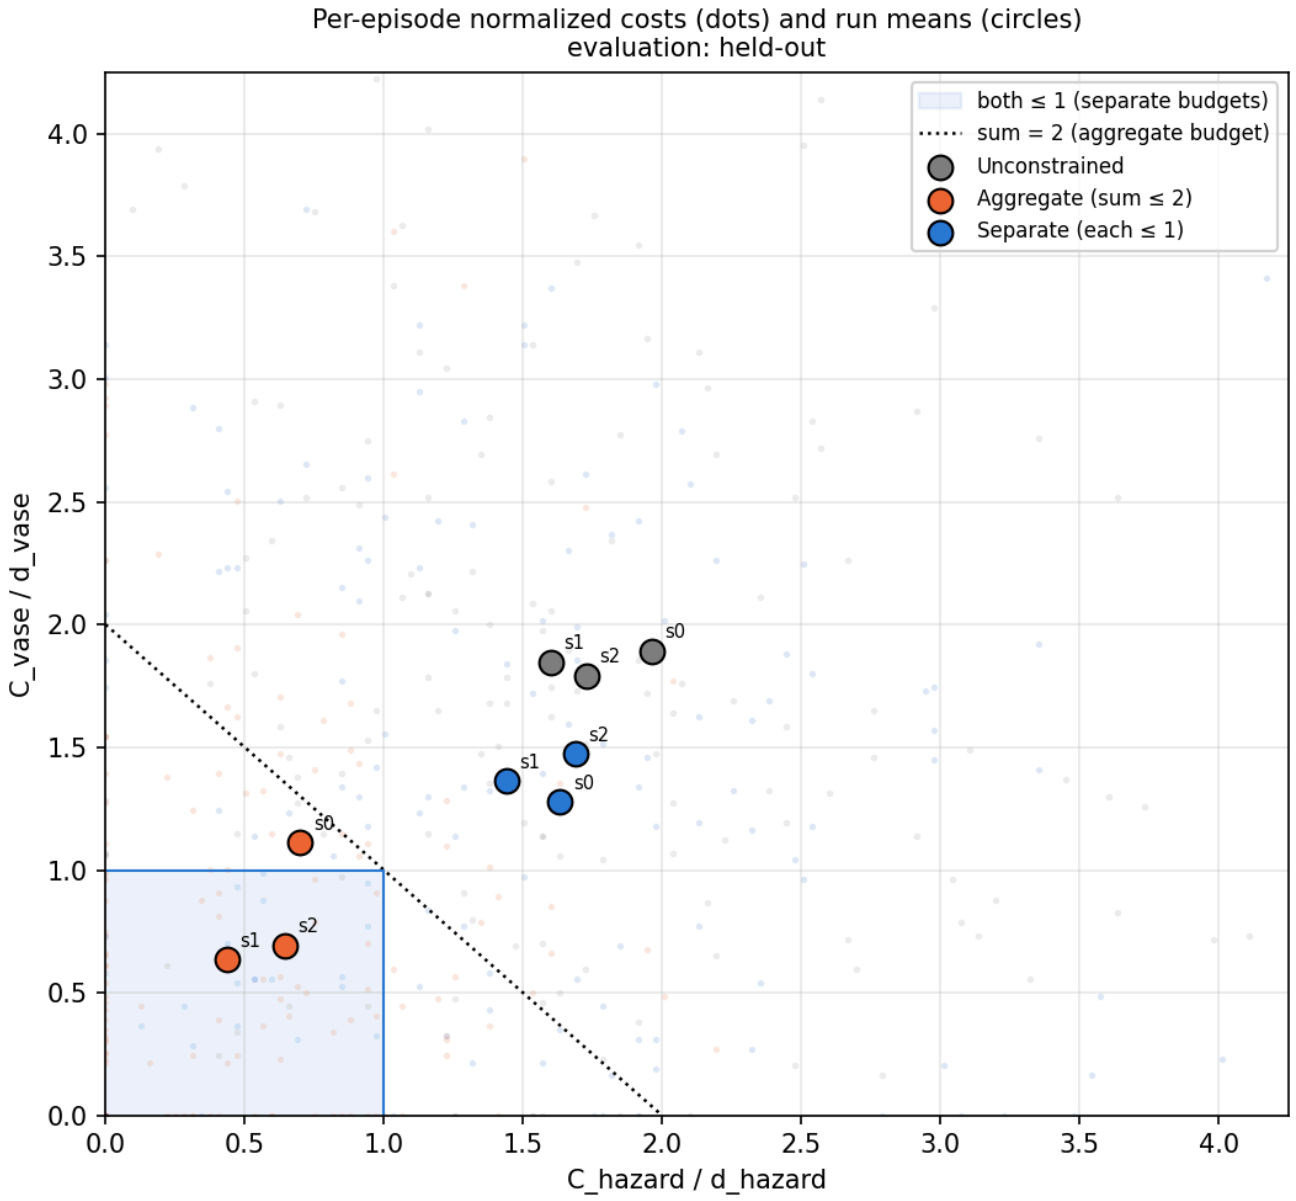
Results

- **Aggregate**: over-constrained되어 있음. return을 크게 잃었고, 영상을 보면 hazard와 vase를 과도하게 피함
- **Separate**: 아직 제약을 만족시키지 못하고 hazard에 들어감. budget을 넘음

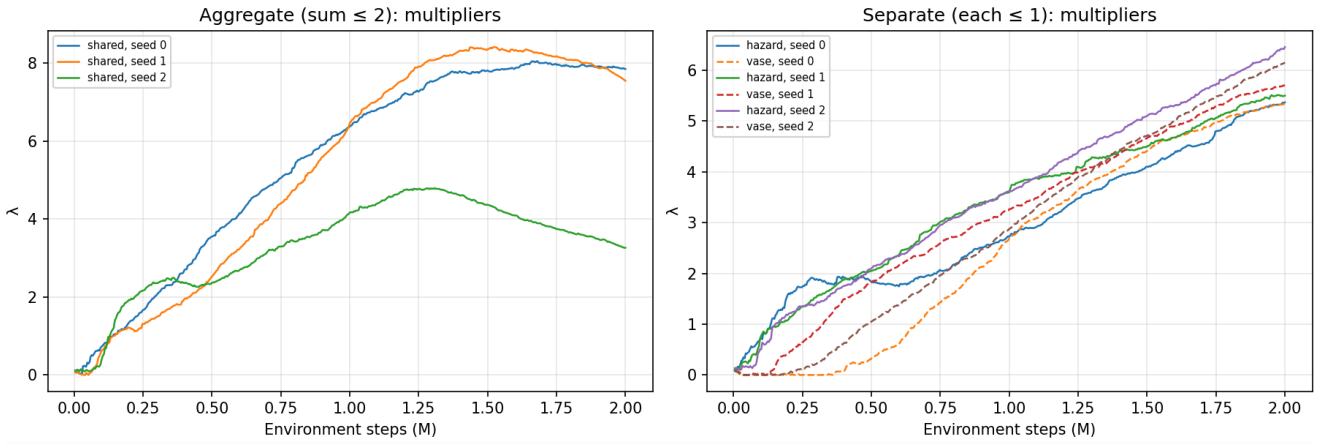
Discussion

- seed 0에서 (hazard, vase)=(0.7, 1.1) 인 경우가 생김 → 실제로 서로 다른 2개의cost를 사용했을 때는 sum<=2인데
- aggregate는 2개가 합쳐서 2를 안 넘어야 하고, separate는 각각 1을 안 넘어야 해서, loose 구간이 더 크다.
- 따라서 그래프를 생각해보면 separate가 더 강한 제약 조건이 된다. 그렇기 때문에,
  - 그래프 아래 면적이 같도록?
  - 합이 1을 안 넘도록?

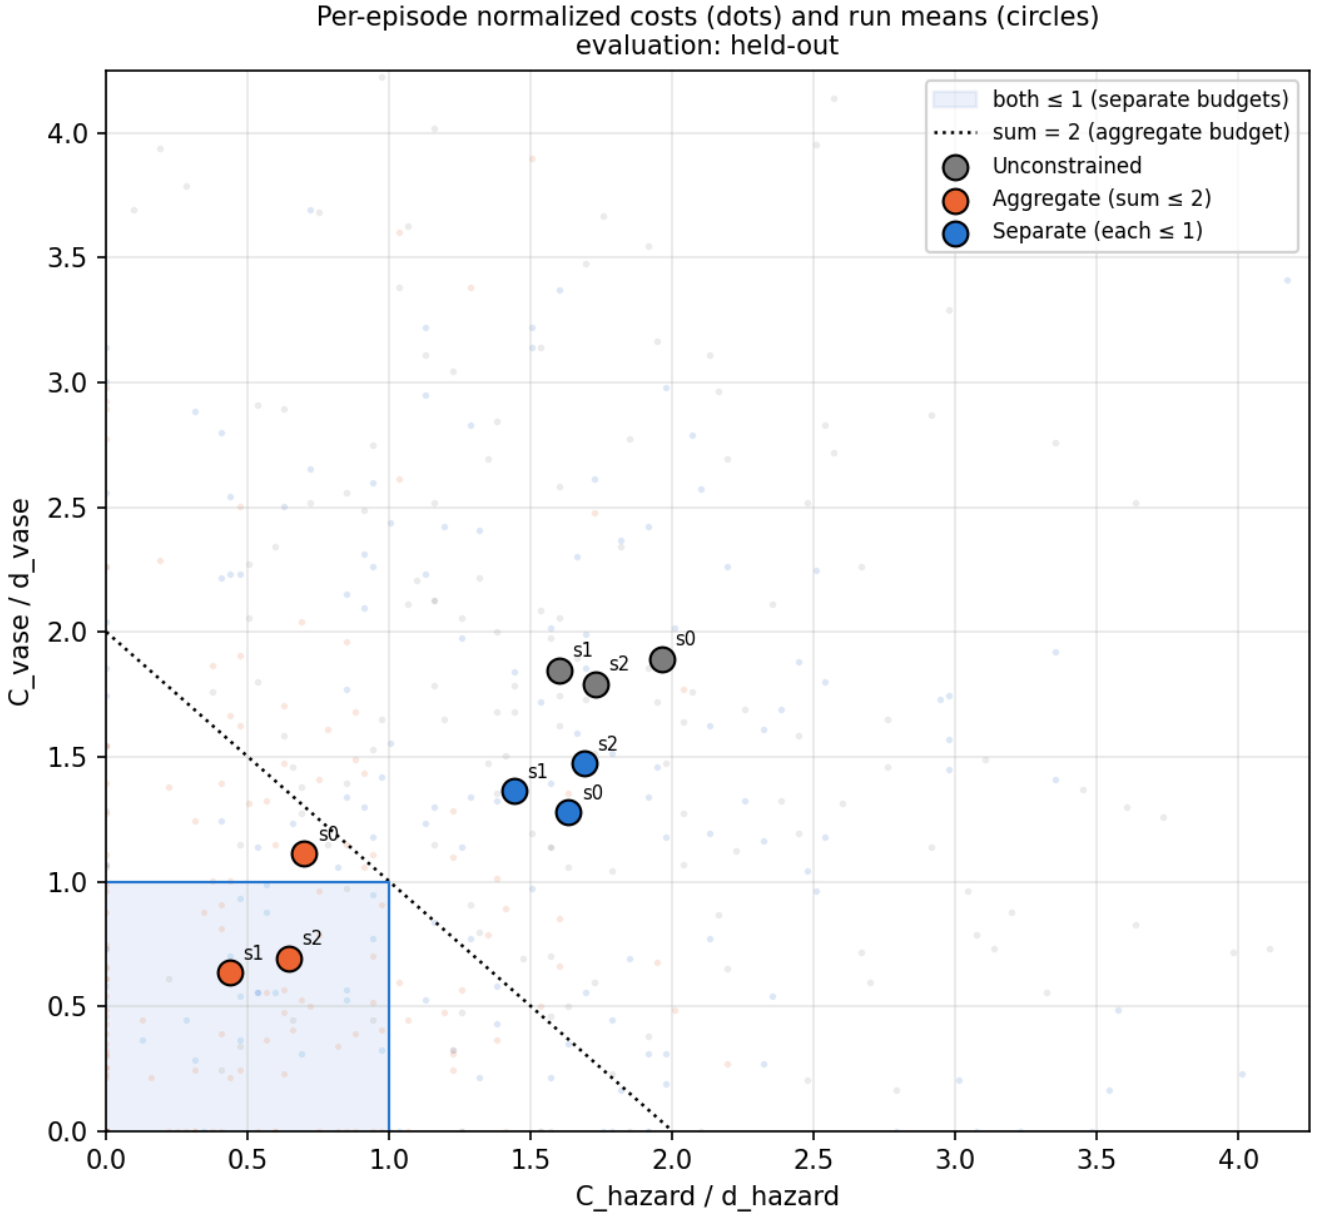
- λ의 업데이트 속도가 다르다. aggregate의 λ는 두 제약을 합쳐서 업데이트되고, separate보다 cost별 penalty가 2배로 커짐.
- 2M step 안에 converge하지 않았기 때문에 learning rate를 크게 해서 다시 학습시켜야 할 것으로 보임 (실험 돌려보는 중)



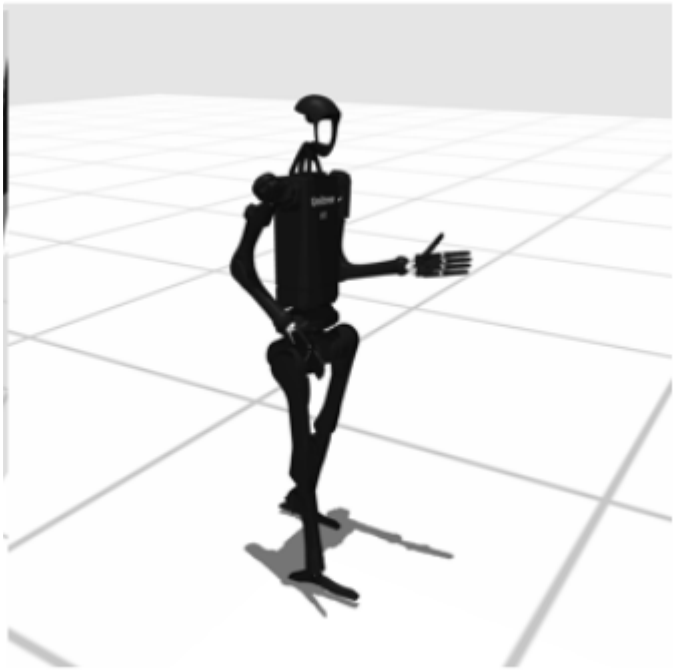




	return	goals/ep	x_hazard	x_vase	합	둘 다 ≤ 1인 seed
Unconstrained	22.4	8.6	1.76	1.84	3.60	0/3
Aggregate	12.2	5.0	0.59	0.81	1.41	2/3
Separate	19.3	7.6	1.59	1.37	2.96	0/3



HumanoidBench H1?



walk

Experimental setup

- h1-walk-v0에서 일반적으로 로봇이 넘어지는 경우들을 분석해서 cost 3개로 유형화 후 각각에 대해 cost vector λ로 사용.
- reward는 건드리지 않음
  1. Fall risk (넘어짐):
     - 몸의 균형이 망가져서 넘어지는 경우.
     - 머리가 일정 높이 이하로 떨어지거나, 몸통이 45도 이상 기울어지거나, 넘어지는 경우
  2. Joint-limit proximity (관절 한계):
     - 관절이 한계 이상으로 꺾인 경우. (limit의 5%로 잡음)
  3. Actuator load (모터 부하):
     - 모터에 힘이 과하게 걸리는 경우 (limit의 5%로 잡음)
- horizon (하나의 episode에서 허용하는 최대 step 수) = 256
- 빨리 넘어지면 이후 episode에서의 cost가 줄어들어서, 빨리 넘어지는 방법으로 cost를 피해버릴 수가 있기 때문에, 넘어지고 나서도 계속 페널티를 주도록 만듦

Results

- MuJoCo step수 약 133,654/전체 training steps 614,400
- 실제 물리 step은 21.8%에서 끝남 → 모든 경우에 그냥 넘어져서 학습이 제대로 안 됐다.
- fall risk에 대한 multiplier를 아주 크게 높였는데도 해결x

Discussion

unconstrained 상태에서 제대로 걷게 하는 것도 어렵다. pretrained policy를 사용?
시간이 부족해서 환경에 대해서 아직 깊게 파보지 않았는데 환경에 대해서 공부를 더 해야 하고, 학기 중에 더 많은 추가적인 실험을 해야 할 것으로 보임.

Note

- 제 개인 컴퓨터인 MacBook Air (RAM 16GB) 환경에서는 Safety Gymnasium 실험만 진행해도 CPU가 부족했음
  - 다른 과목에서 쓰고 있는 cse edu cluster + vast.ai 사용함
- Humanoid-Bench 등에 대해서 돌리기엔 역부족...
- 앞으로 학기 중 추가 실험을 위해서는 CPU core와 메모리가 넉넉한 환경이 있으면 좋을 것 같음.

Research topic for CSED499II

과제연구2 주제

Hierarchical Multi-Cost Safe Reinforcement learning

- multi-constraint safety에서의 priority를 어떻게 정할 수 있을까?
- 로봇의 안전 요구에는 치명적 충돌처럼 실행 시점에 막아야 하는 조건과, 에너지 사용·물체 접촉처럼 일정 budget 안에서 허용하는 누적 비용이 함께 존재함
- 여러 가지 budget이 동시에 만족하기 어려울 경우,

1. 사람과 충돌하지 않게 한다
2. 로봇 팔, 다리와 같이 비싼 것들이 손상되지 않게 한다
3. 로봇 모터, 관절 등 교체가 쉬운 부품의 손상을 막는다

TODO:

- lexicographic RL 공부
- LexiSafe, 2026 (여러 safety cost의 hierarchy, offline rl 설정)
- Hierarchical Relaxation, IROS 2023
- 서버
- read https://openaccess.thecvf.com/content/CVPR2024/papers/Guan_POCE_Primal_Policy_Optimization_with_Conservative_Estimation_for_Multi-constraint_Offline_CVPR_2024_paper.pdf

https://arxiv.org/pdf/2602.17312